

Projet Fashion-MNIST : classification et clustering

LU3IN0226 - IA & Data science

Noms : Mehdi Qostali et Hakim Ziane

Lecture rapide

La forêt aléatoire est le meilleur modèle supervisé testé : 0,8535 en binaire et 0,8700 en multi-classe.

Les erreurs viennent surtout des vêtements du haut : *Shirt*, *T-shirt/top*, *Pullover* et *Coat*.

1 Données

images + labels

2 Préparation

normalisation

3 Modèles

supervisé + clusters

4 Évaluation

accuracy, ARI, NMI

0,8535

Accuracy test binaire

0,8700

Accuracy test multi-classe

0,611

NMI hiérarchique

86,6 %

Variance gardée par l'ACP

Données et objectif

Fashion-MNIST contient 10 classes : T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag et Ankle boot.

Le but est de comparer plusieurs modèles supervisés, puis de voir si le clustering retrouve des groupes cohérents sans utiliser les labels pendant l'apprentissage.

Préparation

Chaque image est représentée par 784 pixels et les valeurs sont normalisées dans [0, 1].
Les validations croisées sont faites sur des échantillons stratifiés : chaque classe reste représentée dans les mêmes proportions.
Le test final utilise `fashion-mnist_test.csv`.

Lecture des matrices

Ligne = vraie classe. Colonne = classe prédite.
Bleu clair = peu d'exemples. Bleu foncé = beaucoup d'exemples.
La diagonale indique les bonnes prédictions. Les autres cases indiquent les erreurs.


À retenir

Les classes les plus simples sont celles dont la silhouette est très différente, par exemple les sacs, les pantalons et plusieurs chaussures.
Les vêtements du haut se ressemblent davantage, ce qui explique la plupart des confusions.

Résultats supervisés

Binaire. La tâche T-shirt/top vs Shirt est difficile, car les formes sont proches. La forêt aléatoire atteint 0,8535 sur le test.
Multi-classe. Sur les 10 classes, la forêt aléatoire atteint 0,8700 après entraînement sur 20 000 exemples.

Comparaison des classifieurs



La forêt aléatoire donne les meilleurs scores parmi les modèles testés.

Erreurs les plus fréquentes

Vraie classe → classe prédite	Nb
Shirt → T-shirt/top	179
Pullover → Coat	113
Shirt → Pullover	112
Shirt → Coat	90
T-shirt/top → Shirt	85

La classe *Shirt* est la plus fragile : son rappel est autour de 0,566.


Interprétation

La forêt aléatoire sépare bien les classes très différentes, mais elle hésite quand plusieurs vêtements ont une forme globale proche en 28 × 28 pixels.

Non-supervisé

Avant le clustering, une ACP réduit la dimension.
Pour k-means, 50 composantes principales gardent environ 86,6 % de la variance.
Pour le hiérarchique, on utilise 500 exemples et 20 composantes pour limiter le coût.

Scores de clustering



k = 10 est retenu pour correspondre aux 10 classes Fashion-MNIST.

Résultats de clustering

k-means : ARI ≈ 0,385 et NMI ≈ 0,536 avec k = 10.
Hiérarchique : ARI ≈ 0,430 et NMI ≈ 0,611 sur 500 exemples.
Les groupes sont cohérents visuellement, mais ne recouvrent pas parfaitement les 10 labels.

Bilan et pistes

Le supervisé reste plus performant pour prédire les labels.
Pour améliorer : entraîner sur toute la base, optimiser les hyper-paramètres, tester un modèle convolutionnel et analyser séparément Shirt, Pullover, Coat et T-shirt/top.